

Ausführliche Analysestrategie:

Von diesen Maßzahlen für die Diskrepanz einzelner Aufgaben lässt sich dann ebenfalls das arithmetische Mittel über alle Aufgaben berechnen, um zu beobachten, ob sich eine Person eher überschätzt oder unterschätzt. Es besteht das Risiko, dass sich die Werte einer Person gegenseitig neutralisieren. Soweit die mittlere absolute Abweichung (MAD), um zu sehen, wie viel im Mittel eine Person von ihrer Selbstausskunft abweicht. Die Limitation hierbei ist, dass man keine Schlüsse über die Effektrichtung ziehen kann. Vorteil ist, dass kein Risiko besteht, dass Werte sich neutralisieren können.

Nach der Datenaufbereitung wird der Forschungsfrage erst deskriptiv genähert, um einen Überblick darüber zu bekommen, wie stark die Unterschiede zwischen beobachtetem und selbstangabem Verhalten sind. Dazu werden MAD und arithmetische Mittel von der Diskrepanz der Aufgaben berechnet, sowie ein Überblick über die Stichprobe gegeben.

Die explorative Analyse der gewonnenen Daten soll mittels einer k-medoids-Clusteranalyse durchgeführt werden. Da die Variablen die in das Cluster einfließen sollen, aus fünf kontinuierlichen Diskrepanzscores (Kategorien der Informationsnutzung) und zwei ordinalskalierten und gerichteten Diskrepanzkategorien (kritisches Nachfragen und Sentiment) bestehen, liegen ein gemischte Skalenniveaus vor. Die Manhattan-Distanz und Euklidische-Distanz, die in der Literatur sehr prominent sind, benötigen metrische oder binäre Daten. Für das Clustering wird daher die Gower-Distanz verwendet, die unterschiedliche Skalenniveaus in einer gemeinsamen Distanzmatrix kombiniert (Gower 1971). Die Idee der Gower-Distanz ist, dass für alle Variablen eine eigene Distanz berechnet wird, die immer zwischen 0 und 1 liegt. Diese berechneten Einzel-Distanzen werden am Ende in einer Gesamtdistanz pro Personenpaar verrechnet, bei der 0 bedeutet, dass die Personen identisch sind und 1 bedeutet, dass sie möglichst unterschiedlich sind. Von den kontinuierlichen Variablen A_i wird die absolute Differenz genommen, während $S_{Diskrepanz}$ und $K_{Diskrepanz}$ zuerst als geordnete Faktoren codiert werden, damit ihre Richtung (Unter- vs. Überschätzung) erhalten bleibt und nicht wie bei einer rein nominalen Codierung verloren geht. Anschließend werden die ordinalen Maßzahlen in Ränge übersetzt. Da die inhaltliche Domäne mit fünf Variablen gegenüber Sentiment und Kritik mit je einer Variable bei Gleichgewichtung aller einzelnen Variablen überproportional stark in die Distanz eingeht, werden die 5 aufgabenspezifische Diskrepanzmaße mit $\frac{1}{5} = 0,2$ gewichtet.

Der Algorithmus, der für die Clusteranalyse verwendet wird, ist der "Partitioning around Medoids"-Algorithmus, kurz PAM (Kaufman und Rousseeuw 1990). Dieser funktioniert wie folgt: Wie der k-means-Algorithmus wird er den Datensatz in eine Anzahl von k-Partitionen unterteilen. Dabei werden aber statt des arithmetischen Mittels oder des Medians, tatsächliche Beobachtungseinheiten, als Clusterzentrum gewählt. Dies erlaubt auch, dass beliebige Distanzmaße verwendet werden können und man nicht wie bei k-means auf die euklidischen Distanzmaße beschränkt ist, die metrische oder binäre Daten verwenden. Da Personen als Zentrum der k-Partitionen erlaubt PAM, dass man die Cluster-Zentren intuitiver interpretieren kann, so kann man diese Person, die im Zentrum steht, als eine Art Idealtyp des Clusters interpretieren, dem die anderen Personen ähneln. Dies macht den Algorithmus zu einer attraktiven Wahl für unser exploratives Vorhaben. Die Struktur des Algorithmus funktioniert wie folgt: Zu Beginn werden per Zufall drei Beobachtungen ausgewählt (dies

wird durch einen Seed "404" replizierbar gehalten). Danach werden alle Personen dem Medoid (Zentrum) zugeordnet, an dem sie am nächsten liegen, und die Summe aller Distanzen von den Personen zu ihrem Medoid berechnet. Schließlich werden die Beobachtungen, die Medoid sind, mit Beobachtungen, die nicht-Medoid sind, ausgetauscht. Dieser Prozess wiederholt sich, bis keine Verbesserung mehr möglich ist.

Die Anzahl der k-Partitionen wird mittels der Silhouette-Methode von Rousseeuw (1987) festgelegt und nicht wie bei einer k-means-Clusterung mit dem Elbow-Kriterium. Dabei wird berechnet, ob und wie viel die Distanz einer Person zum nächsten fremden Cluster größer ist als die Distanz innerhalb der eigenen Gruppe. Das Ergebnis liegt im Intervall von $[-1, 1]$, wobei 1 heißt, dass die Person sehr gut in das Cluster passt, 0, dass es uneindeutig ist, und -1, dass die Person näher an einem anderen Cluster ist. Nun rechnet man den Durchschnitt für alle Personen aus, der anzeigt, wie eng gruppiert alle Personen in dem Cluster sind. Ein Cluster mit einer durchschnittlichen Silhouette von 0,5 wird als ausreichend für unsere Zwecke betrachtet, 0,7 als stark. Dieser Prozess wird für $k = 2$ bis $k = 6$ wiederholt. Die Anzahl k , für die die maximale durchschnittliche Silhouette berechnet wird, wird verwendet.

Nachdem die Cluster stehen, können diese noch auf inhaltliche Unterschiede überprüft werden. Dazu werden die einzelnen Cluster auf Unterschiede in den im Fragebogen erhobenen Kontextvariablen untersucht, also beispielsweise Studiengang, soziale Erwünschtheit und Erfahrung mit künstlicher Intelligenz. Erst wird ein deskriptiver graphischer Überblick gegeben und im Anschluss die einzelnen Werte zwischen den Gruppen statistisch verglichen. Dafür wird für die soziale Erwünschtheit, die in eine Skala umgewandelt wird, eine Anova durchgeführt. Für die ordinal skalierten Variablen, also Erfahrung mit künstlicher Intelligenz, Nutzungshäufigkeit und Informationsnutzung, wird Kruskal-Wallis berechnet, da dort keine Annahme über die Abstände der Ausprägungen getroffen werden muss, da alle Beobachtungen in Ränge eingeteilt werden. Für die nominalskalierten Variablen wird ein Chi-Quadrat-Test durchgeführt.