

Ergebnisbericht der LLM-Evaluation

Theo Wiesholler¹, Hannah Laier², and Laura Kiemes³

^{1,2,3}LMU München

29.06.2026

Abstract

Dieser Report skizziert die Ergebnisse verschiedener GPT-Modelle von OpenAI in der Klassifikation von *Inhalt*, *Sentiment* und *Kritischem Nachfragen*. Die Modelle wurden an einem Datensatz ($n = 30$, $N = 3$) von 30 GPT-Chatverläufen für verschiedene Prompts getestet. GPT-5.5 schneidet als aktuelles Frontier-Modell in allen Kategorien am besten ab: für die Klassifikation von *Inhalt* mit einer Accuracy von 0,90 und F1 von 0,67, für *Sentiment* mit einer Accuracy von 0,90 und F1 von 0,78 sowie für *Kritisches Nachfragen* mit einer Accuracy von 0,87 und F1 von 0,81.

Einleitung

Um die Leistung der Modelle von OpenAI in Bezug auf die geforderten Aufgaben zu prüfen, wird ein Gold-Label-Datensatz benötigt. Dieser Datensatz umfasst 30 Chats ($n = 30$), da jede der drei Forschenden ($N = 3$) 10 private ChatGPT-Verläufe zur Verfügung gestellt hat. Jeder dieser Chats wurde von allen Forschenden unabhängig voneinander in den drei Kategorien *Inhalt*, *Sentiment* und *Kritisches Nachfragen* gelabelt und anschließend verglichen. Danach einigten sich die Forschenden für jedes Label, bei dem Uneinigkeit bestand, auf ein gemeinsames Gold-Label. Um die Leistung der Modelle zu messen, werden Accuracy, Precision, Recall, F1 (macro), Unknown-Rate und Latenz (s) berechnet. Die Modelle wurden auf zwei verschiedene Arten eingesetzt: *combined*, d. h. alle Aufgaben wurden in einem Prompt abgefragt (geringere Kosten, höhere Komplexität), sowie *separate*, d. h. für jede Aufgabe wurde ein separater API-Aufruf gesendet (höhere Kosten, geringere Komplexität). Um die Leistung der Modelle zu steigern, wurden die Prompts über mehrere Runden angepasst.

Ermittlung des Gold-Standards

Um den Aufwand im Labeling-Prozess sowie die Kosten der API-Nutzung zu reduzieren, wurden im weiteren Verlauf nur die Nutzernachrichten der Chatverläufe verwendet. In der ersten Runde des Labelings durch die Forschenden wurden für die verschiedenen Klassifikationen folgende Labels verwendet:

Table 1: Kategorien und Antwortausprägungen

Kategorie	Ausprägung
Inhalt	Informationssuche und Verständnis Schreiben und Textarbeit Praktische Unterstützung und Strukturierung Technische und analytische Unterstützung Lernen und Prüfungsvorbereitung
Sentiment	1 = Sehr unfreundlich 2 = Unfreundlich 3 = Neutral 4 = Freundlich 5 = Sehr freundlich
Kritisches Nachfragen	1 = Stimme nicht zu 2 = Stimme eher nicht zu 3 = Teils, teils 4 = Stimme eher zu 5 = Stimme zu

Um die Übereinstimmung der Labels der Forschenden zu bestimmen, wurde Krippendorffs Alpha berechnet. Krippendorffs Alpha wird ermittelt, indem die beobachtete Unstimmigkeit zwischen den Kodierenden (D_o) mit der erwarteten Unstimmigkeit durch zufällige Übereinstimmung (D_e) verglichen wird.

(i) Beobachtete Unstimmigkeit

$$D_o = \frac{\sum_{i=1}^{30} \frac{1}{n_i - 1} \sum_c \sum_k o_{ick} \delta_{ck}^2}{\sum_{i=1}^{30} n_i}, \quad n_i = 3.$$

(ii) Erwartete Unstimmigkeit

$$D_e = \frac{\sum_c \sum_k n_c n_k \delta_{ck}^2}{N_{\text{tot}}(N_{\text{tot}} - 1)}, \quad N_{\text{tot}} = 30 \cdot 3 = 90.$$

Es gilt:

$$\text{Nominal: } \delta_{ck}^2 = \begin{cases} 0, & c = k, \\ 1, & c \neq k, \end{cases} \quad c, k \in \mathcal{C} \quad \text{Ordinal: } \delta_{ck}^2 = \left(\frac{r_c - r_k}{R - 1} \right)^2, \quad r_c, r_k \in \{1, \dots, R\}, \quad R \in \mathbb{N}$$

(iii) Krippendorffs Alpha

$$\alpha = 1 - \frac{D_o}{D_e}$$

In der ersten Labeling-Runde betrug Krippendorffs Alpha für *Inhalt* 0,628, für *Sentiment* 0,258 und für *Kritisches Nachfragen* 0,338. Kodiererin 3 zeigte für *Sentiment* und *Kritisches Nachfragen* ein abweichendes Labeling-Verhalten. Zudem war das Label für *Kritisches Nachfragen* in sich nicht schlüssig, da sich in einem Chat nur schwer ein *Teils/teils* abbilden lässt. Im Zuge dieser Reflexion wurde beschlossen, das Label für *Kritisches Nachfragen* auf eine binäre Skala zu reduzieren: Es wurde kritisch nachgefragt (*Ja*) oder nicht (*Nein*). Ebenso wurde *Sentiment* auf drei Kategorien (*Unfreundlich*, *Neutral*, *Freundlich*) reduziert, um die Kategorisierung zu erleichtern. Nach einer Wiederholung des Labeling-Prozesses verbesserte sich Krippendorffs Alpha für *Sentiment* auf 0,460 und für *Kritisches Nachfragen* auf 0,491. Obwohl diese Werte weiterhin moderat sind, konnten sich die Forschenden in einer gemeinsamen Diskussion schnell auf ein Gold-Label einigen.

LLM-Evaluation

Evaluationsmetriken

Um die Modelle zu bewerten, wurden die folgenden Metriken berechnet: Accuracy (Genauigkeit), Precision (Präzision), Recall (Trefferquote), Macro-F1 sowie die Latenz. Accuracy misst den Anteil der korrekt klassifizierten Beispiele an allen Beispielen. Precision beschreibt, wie viele der als positiv vorhergesagten Fälle tatsächlich positiv sind. Recall gibt an, wie viele der tatsächlich positiven Fälle korrekt erkannt wurden. Der F1-Score stellt das harmonische Mittel aus Precision und Recall dar und fasst beide Aspekte in einer einzigen Kennzahl zusammen. Der Macro-F1 aggregiert die F1-Scores aller Klassen, indem jede Klasse gleich gewichtet wird, unabhängig von ihrer Häufigkeit im Datensatz. Da es sich bei der Sentiment-Klassifikation zum Beispiel um ein stark unausgeglichenes Klassenset handelt (eine dominante neutrale oder positive Klassen gegenüber seltenen negativen Ausprägungen), ist der Macro-F1 besonders aussagekräftig. Er verhindert, dass das Modell gute Ergebnisse auf häufige Klassen erzielt, während seltene, aber inhaltlich wichtige Klassen vernachlässigt werden. Dadurch bietet er eine fairere Bewertung der Modellleistung über alle Sentiment-Kategorien hinweg. Im Gegensatz dazu würden Accuracy oder ein global aggregierter F1-Score die Mehrheitsklassen überproportional stark gewichten und die Leistung auf Minderheitsklassen verschleiern. Im folgenden wird nur der Macro-F1 berichtet. Die Latenz beschreibt die Zeit, die ein Modell für eine einzelne Vorhersage benötigt. Sie ist nicht zu wichtig für uns, da wir weder in Echtzeit noch große Datenmengen verarbeiten

Runde 1

Die Prompts die in allen Runden verwendet wurden können im Appendix angeschaut werden. Zuerst wurden Nicht-Frontier-Modelle betrachtet, da diese sehr geringe Kosten aufweisen und angenommen wurde, dass diese für eine Klassifikationsaufgabe ausreichen sollten. GPT-4.1 fiel nach der ersten Runde heraus, da es eine zu starke Input-Token-Begrenzung hatte und infolgedessen nicht alle 30 Chats analysieren konnte. Die Performance der restlichen Modelle war für *Inhalt* in Ordnung, mit einer Accuracy von rund 0,73 über alle Modelle; der F1-Score war bei GPT-5.4-mini am besten mit 0,56 (combined) bzw. 0,46 (separate). Die Erkennung des Sentiments gelang ebenfalls bereits gut, während die Erkennung des kritischen Nachfragens für alle Modelle bis auf GPT-4.1, das in der Folge entfernt wurde, noch nicht zufriedenstellend funktionierte.

Table 2: Evaluierungsergebnisse – Runde 1

Modell	Aufgabe	Strategie	Accuracy	Precision	Recall	F1 (macro)	Latenz (s)
gpt-4.1	Inhalt	combined	0,72	0,30	0,33	0,32	1,57
	Inhalt	separate	0,73	0,41	0,42	0,41	0,45
	Sentiment	combined	0,84	0,62	0,48	0,53	1,57
	Sentiment	separate	0,71	0,38	0,45	0,41	0,79
	Kritisch	combined	0,76	0,55	0,55	0,55	1,57
	Kritisch	separate	0,79	0,42	0,46	0,44	1,26
gpt-4o-mini	Inhalt	combined	0,73	0,42	0,39	0,40	0,57
	Inhalt	separate	0,77	0,44	0,44	0,44	0,63
	Sentiment	combined	0,83	0,79	0,64	0,69	0,57
	Sentiment	separate	0,60	0,31	0,40	0,31	0,47
	Kritisch	combined	0,64	0,48	0,47	0,47	0,57
	Kritisch	separate	0,70	0,39	0,44	0,41	0,52
gpt-5.4-mini	Inhalt	combined	0,74	0,62	0,54	0,56	0,72
	Inhalt	separate	0,77	0,44	0,51	0,46	0,69
	Sentiment	combined	0,77	0,41	0,46	0,43	0,72
	Sentiment	separate	0,77	0,56	0,54	0,53	0,55
	Kritisch	combined	0,57	0,37	0,35	0,36	0,72
	Kritisch	separate	0,73	0,53	0,52	0,52	0,73

Runde 2

In Runde 2 wurden alle Prompts noch einmal geschärft und GPT-5.5 als Frontier-Modell aufgenommen, um GPT-4.1 zu ersetzen. GPT-5.5 ist für eine Aufgabe dieser Art wahrscheinlich überdimensioniert, doch da nach der Feldphase vermutlich nur ein recht kleiner Datensatz mit einer Größe von $n = 150$ ($N = 30$) zu erwarten ist, werden die Kosten nicht allzu hoch skalieren. GPT-5.5 lieferte die stärksten Ergebnisse für Sentiment und Inhalt sowie den höchsten F1-Score für kritisches Nachfragen. GPT-4o-mini lieferte die höchste Accuracy für kritisches Nachfragen mit 0,77, jedoch gepaart mit einem schwachen F1-Score.

Table 3: Evaluierungsergebnisse – Runde 2

Modell	Aufgabe	Strategie	Accuracy	Precision	Recall	F1 (macro)	Latenz (s)
gpt-4o-mini	Inhalt	combined	0,76	0,44	0,44	0,44	1,19
	Inhalt	separate	0,77	0,45	0,44	0,45	0,87
	Sentiment	combined	0,80	0,44	0,40	0,41	1,19
	Sentiment	separate	0,60	0,31	0,40	0,31	0,63
	Kritisch	combined	0,76	0,43	0,43	0,43	1,19
	Kritisch	separate	0,77	0,40	0,48	0,43	0,69
gpt-5.4-mini	Inhalt	combined	0,53	0,40	0,33	0,35	1,03
	Inhalt	separate	0,80	0,48	0,53	0,49	0,78
	Sentiment	combined	0,73	0,44	0,58	0,46	1,03
	Sentiment	separate	0,72	0,39	0,37	0,38	0,79
	Kritisch	combined	0,63	0,46	0,46	0,46	1,03
	Kritisch	separate	0,63	0,46	0,46	0,46	0,86
gpt-5.5	Inhalt	combined	0,87	0,71	0,64	0,65	4,68
	Inhalt	separate	0,90	0,72	0,66	0,66	3,28
	Sentiment	combined	0,87	0,85	0,65	0,72	4,68
	Sentiment	separate	0,83	0,78	0,57	0,63	2,25
	Kritisch	combined	0,63	0,56	0,58	0,55	4,68
	Kritisch	separate	0,63	0,38	0,40	0,39	2,72

Runde 3

In der dritten Runde wurden die Prompts für kritisches Nachfragen und Sentiment noch einmal vollständig überarbeitet und deutlich detaillierter formuliert, in der Hoffnung, dass die beiden bis dahin leistungsstärksten Modelle, GPT-5.4-mini und GPT-5.5, mit zusätzlichem Kontext bessere Werte erzielen können. Dies funktionierte für Sentiment, bei dem GPT-5.5 sogar eine Accuracy von 0,93 (combined) erzielte; Accuracy und F1-Score verschlechterten sich jedoch für kritisches Nachfragen. Precision und Recall sind dagegen gestiegen, was ein gutes Zeichen ist, da es bedeutet, dass die Modelle eine bessere Leistung beim Identifizieren von positiven Fällen erzielen.

Table 4: Evaluierungsergebnisse – Runde 3

Modell	Aufgabe	Strategie	Accuracy	Precision	Recall	F1 (macro)	Latenz (s)
gpt-5.4-mini	Inhalt	combined	0,79	0,44	0,54	0,47	1,28
	Inhalt	separate	0,80	0,46	0,53	0,48	1,17
	Sentiment	combined	0,83	0,51	0,49	0,49	1,28
	Sentiment	separate	0,80	0,45	0,40	0,41	0,98
	Kritisch	combined	0,43	0,56	0,58	0,43	1,28
	Kritisch	separate	0,47	0,64	0,67	0,46	0,83
gpt-5.5	Inhalt	combined	0,90	0,72	0,66	0,67	5,94
	Inhalt	separate	0,83	0,49	0,54	0,50	3,24
	Sentiment	combined	0,93	0,82	0,82	0,82	5,94
	Sentiment	separate	0,87	0,75	0,72	0,72	3,17
	Kritisch	combined	0,50	0,64	0,69	0,49	5,94
	Kritisch	separate	0,43	0,63	0,65	0,43	2,75

Runde 4

In der letzten Runde wurde nur noch GPT-5.5 getestet, da es die stärksten Ergebnisse in Bezug auf Inhalt und Sentiment erzielte. Der Prompt für kritisches Nachfragen wurde angepasst, indem GPT-5.5 ein schrittweises Vorgehen bei der Identifikation von kritischem Nachfragen vorgegeben wurde. GPT-5.5 erzielte für die Combined-Strategie die besten Ergebnisse mit einer Accuracy von 0,90 für Inhalt und Sentiment sowie einer Accuracy von 0,87 für kritisches Nachfragen, dazu einen F1-Score von 0,81 für kritisches Nachfragen, 0,78 für Sentiment und 0,67 für Inhalt.

Table 5: Evaluierungsergebnisse – Runde 4

Modell	Aufgabe	Strategie	Accuracy	Precision	Recall	F1 (macro)	Latenz (s)
gpt-5.5	Inhalt	combined	0,90	0,72	0,66	0,67	7,25
	Inhalt	separate	0,87	0,71	0,64	0,65	3,34
	Sentiment	combined	0,90	0,75	0,81	0,78	7,25
	Sentiment	separate	0,93	0,92	0,82	0,84	2,78
	Kritisch	combined	0,87	0,79	0,85	0,81	7,25
	Kritisch	separate	0,77	0,70	0,79	0,71	4,50

Diskussion der Ergebnisse

GPT-5.5 hat erwartungsgemäß die besten Ergebnisse in allen Aufgabenbereichen erreicht. Überraschend ist hierbei lediglich, dass es besser war, wenn alle Klassifikationen gemeinsam in einem Prompt abgefragt wurden. Wir werden für die quantitative Textanalyse folglich GPT-5.5 verwenden. Da für den Datensatz, den wir in dem Survey erheben wollen, keine Gold-Labels vorliegen, kann keine direkte Evaluation der Modellgüte erfolgen. Die auf dem gelabelten Evaluationsdatensatz ermittelten Zero-Shot-Leistungskennzahlen dienen daher als Schätzung der zu erwartenden Modellperformance. Diese Annahme basiert darauf, dass beide Datensätze hinsichtlich Domäne (Chatverläufe von Studierenden), Aufgabenkontext (wofür GPT eingesetzt wurde), Labelschema und struktureller Ähnlichkeit der Chats (terative Prompt-Verfeinerung, Frage-Antwort-Strukturen) vergleichbar sind. Dennoch können Unterschiede in der Datenverteilung dazu führen, dass die tatsächliche Performance auf dem zweiten Datensatz von den gemessenen Kennzahlen abweicht. Dies könnte insbesondere ein Problem bei der Klassifizierung von Inhalten sein, da die hier analysierten Daten von drei CSS-Masterstudierenden stammen und dementsprechend eine Homogenität der Inhalte zu erwarten ist. GPT-5.5 war in Inhaltsklassifikationen in allen Runden sehr akkurat, was darauf hindeuten könnte, dass dieses Problem nicht von zu großer Bedeutung ist. Um das Problem der Übertragbarkeit zu adressieren, wird eine Stichprobe von 15–20 % des Survey-Datensatzes gezogen, um die von GPT-5.5 vergebenen Labels zu überprüfen.

Appendix

Die folgenden Tabellen dokumentieren die System-Prompts aller vier Runden für die separate sowie die kombinierte Klassifikationsstrategie. Der User-Prompt war über alle Runden hinweg identisch: "Chat-Log:\n{text}" (bzw. mit zusätzlichem "\nLabel:" in Runde 1).

Prompt: Runde 1

Table 6: Separate Prompts – Runde 1

Kriterium	System-Prompt
Inhalt	Du bist ein Klassifikationssystem. Analysiere das folgende Chat-Log und bestimme, welcher Aufgabentyp vorliegt. Aufgabentypen: (1) Informationssuche und Verständnis – z.B. Literaturhinweise, Begriffe erklären, Verständnisfragen (2) Schreiben und Textarbeit – z.B. Feedback, Gliederungen, Zusammenfassungen, Übersetzungen (3) Praktische Unterstützung und Strukturierung – z.B. Ideen entwickeln, Projekte strukturieren, Planung (4) Technische und analytische Unterstützung – z.B. Code, Datenanalyse, Statistik (R/SPSS/Stata) (5) Lernen und Prüfungsvorbereitung – z.B. Prüfungsvorbereitung, Lernfragen, Karteikarten Antworte NUR mit EINEM der folgenden Labels (exakt so): {labels}
Sentiment	Du bist ein Klassifikationssystem. Analysiere den Ton des folgenden Chat-Logs. Bewerte den Ton als: • Unfreundlich: abweisend, fordernd, ungeduldig • Neutral: sachlich, nüchtern, aufgabenorientiert • Freundlich: höflich, wertschätzend, kooperativ Antworte NUR mit EINEM der folgenden Labels (exakt so): {labels}
Kritisches Nachfragen	Du bist ein Klassifikationssystem. Analysiere das folgende Chat-Log. Fragt die Person ChatGPT nach Hinweisen zur Überprüfung der Antwort, z. B. Quellen, Belege, Gegenargumente oder einer Prüfung auf mögliche Fehler? Antworte NUR mit EINEM der folgenden Labels (exakt so): {labels}

Table 7: Kombinerter Prompt – Runde 1

System-Prompt
Du bist ein Klassifikationssystem für akademische Chat-Logs. Analysiere das folgende Chat-Log und klassifiziere es nach drei Kriterien. KRITERIUM 1 – Aufgabentyp: (1) Informationssuche und Verständnis – z.B. Literaturhinweise, Begriffe erklären (2) Schreiben und Textarbeit – z.B. Feedback, Gliederungen, Übersetzungen (3) Praktische Unterstützung und Strukturierung – z.B. Ideen entwickeln, Planung (4) Technische und analytische Unterstützung – z.B. Code, Datenanalyse, R/SPSS (5) Lernen und Prüfungsvorbereitung – z.B. Prüfungsvorbereitung, Karteikarten KRITERIUM 2 – Ton/Sentiment: • Unfreundlich: abweisend, fordernd, ungeduldig • Neutral: sachlich, nüchtern, aufgabenorientiert • Freundlich: höflich, wertschätzend, kooperativ KRITERIUM 3 – Kritische Überprüfung: Fragt die Person nach Quellen, Belegen, Gegenargumenten oder Fehlerprüfung? • Ja • Nein Antworte NUR in diesem exakten Format (drei Zeilen, nichts anderes): TASK: <Label> SENTIMENT: <Label> CRITICAL: <Label>

Prompt: Runde 2

Table 8: Separate Prompts – Runde 2

Kriterium	System-Prompt
Inhalt	Du bist ein Klassifikationssystem. Analysiere das folgende Chat-Log und bestimme, welcher Aufgabentyp in diesem Chat vorhanden ist. Wenn mehrere Aufgabentypen vorkommen, wähle den dominanten. Aufgabentyp: (1) Informationssuche und Verständnis, z.B. um Literaturhinweise, Suchbegriffe oder Rechercheansätze zu erhalten, Theorien und Konzepte erklären zu lassen oder Verständnisfragen zu Studieninhalten zu klären. (2) Schreiben und Textarbeit, z.B. um Feedback zu eigenen Texten zu erhalten, Gliederungen zu erstellen, Texte zusammenfassen zu lassen, Textbausteine oder Formulierungsvorschläge zu erstellen oder Texte zu übersetzen bzw. sprachlich zu überarbeiten. (3) Praktische Unterstützung und Strukturierung, z.B. um Ideen für eine Hausarbeit, einen Essay oder eine Präsentation zu entwickeln, ein Projekt zu strukturieren, nächste Arbeitsschritte zu planen oder Unterstützung bei Problemlösung und Entscheidungsfindung zu erhalten. (4) Technische und analytische Unterstützung, z.B. um Code zu erstellen oder zu überarbeiten, Datenanalysen oder Datenvisualisierungen vorzubereiten oder Ergebnisse aus Statistik- und Analyseprogrammen wie R, Stata oder SPSS interpretieren zu lassen. (5) Lernen und Prüfungsvorbereitung, z.B. um sich auf Prüfungen vorzubereiten oder Lernfragen, Übungsaufgaben oder Karteikarten zu erstellen. Antworte NUR mit EINEM der folgenden Labels (exakt so): {labels}
Sentiment	Du bist ein Klassifikationssystem. Analysiere den Ton des folgenden Chat-Logs. Bewerte den Ton als: • Unfreundlich: abweisend, fordernd, ungeduldig • Neutral: sachlich, nüchtern, aufgabenorientiert • Freundlich: höflich, wertschätzend, kooperativ Antworte NUR mit EINEM der folgenden Labels (exakt so): {labels}
Kritisches Nachfragen	Du bist ein Klassifikationssystem. Analysiere das folgende Chat-Log. Fragt die Person ChatGPT nach Hinweisen zur Überprüfung der Antwort, z.B. Quellen, Belege, Gegenargumente oder eine Prüfung auf mögliche Fehler. Antworte NUR mit EINEM der folgenden Labels (exakt so): {labels}

Table 9: Kombiniertes Prompt – Runde 2

System-Prompt
Du bist ein Klassifikationssystem für akademische Chat-Logs. Analysiere das folgende Chat-Log und klassifiziere es nach drei Kriterien. KRITERIUM 1 – Aufgabentyp: (identisch zum separaten Prompt, siehe Tabelle 8) KRITERIUM 2 – Ton/Sentiment: Bewerte den Ton als: • Unfreundlich: abweisend, fordernd, ungeduldig • Neutral: sachlich, nüchtern, aufgabenorientiert • Freundlich: höflich, wertschätzend, kooperativ KRITERIUM 3 – Kritische Überprüfung: Fragt die Person ChatGPT nach Hinweisen zur Überprüfung der Antwort, z.B. Quellen, Belege, Gegenargumente oder eine Prüfung auf mögliche Fehler. • Ja • Nein Antworte NUR in diesem exakten Format (drei Zeilen, nichts anderes): TASK: <Label> SENTIMENT: <Label> CRITICAL: <Label>

Prompt: Runde 3

Table 10: Separate Prompts – Runde 3

Kriterium	System-Prompt
Inhalt	Unverändert gegenüber Runde 2 (siehe Tabelle 8).
Sentiment	Du bist ein Klassifikationssystem für akademische Chat-Logs. Analysiere den Kommunikationsstil der Person im folgenden Chat-Log. Beachte: Es handelt sich um Studierende, die ChatGPT für akademische Aufgaben nutzen. Der Großteil der Chats ist neutral-sachlich – sei bei der Vergabe von “Freundlich” und “Unfreundlich” konservativ. Vergib <i>Unfreundlich</i>, wenn die Person: • sehr kurze, befehlsartige Nachrichten schreibt • Ungeduld oder Frustration zeigt • fordernd oder abweisend wirkt Vergib <i>Freundlich</i>, wenn die Person: • Begrüßungen verwendet • explizit “bitte” oder “danke” schreibt • Wertschätzung oder positive Rückmeldung ausdrückt Vergib <i>Neutral</i>, wenn die Person: • sachlich und aufgabenorientiert schreibt • technische Fragen oder Code ohne emotionalen Ton stellt • direkt zur Sache kommt ohne besondere Freundlichkeit oder Unfreundlichkeit • im Zweifel: Neutral ist der Standard für akademisch-technische Chats Antworte NUR mit EINEM der folgenden Labels (exakt so): {labels}

Table 10: Separate Prompts – Runde 3

Kriterium	System-Prompt
Kritisches Nachfragen	Du bist ein Klassifikationssystem für akademische Chat-Logs. Analysiere das folgende Chat-Log und bestimme, ob die Person die Antworten von ChatGPT aktiv überprüft oder hinterfragt. Vergib <i>Ja</i>, wenn die Person mindestens EINES der folgenden Verhaltensweisen zeigt: • fragt explizit nach Quellen, Belegen oder Literatur zur Überprüfung • meldet, dass eine Antwort falsch oder unvollständig war, und korrigiert • hinterfragt ein Ergebnis kritisch • bittet um Gegenargumente oder alternative Perspektiven • exportiert den Chatverlauf zur eigenen Kontrolle • wiederholt eine Anfrage, weil das erste Ergebnis nicht gepasst hat Vergib <i>Nein</i>, wenn die Person: • die Antworten von ChatGPT einfach übernimmt, ohne zu hinterfragen • nur neue unabhängige Fragen stellt, ohne frühere Antworten zu prüfen • ausschließlich neue Aufgaben delegiert Antworte NUR mit EINEM der folgenden Labels (exakt so): {labels}

Table 11: Kombiniertes Prompt – Runde 3

System-Prompt
Du bist ein Klassifikationssystem für akademische Chat-Logs. Analysiere das folgende Chat-Log und klassifiziere es nach drei Kriterien. KRITERIUM 1 – Aufgabentyp: (identisch zu Runde 2, siehe Tabelle 8) KRITERIUM 2 – Ton/Sentiment: (identisch zum separaten Sentiment-Prompt dieser Runde, siehe Tabelle 10) KRITERIUM 3 – Kritische Überprüfung: (identisch zum separaten Critical-Prompt dieser Runde, siehe Tabelle 10) Antworte NUR in diesem exakten Format (drei Zeilen, nichts anderes): TASK: <Label> SENTIMENT: <Label> CRITICAL: <Label>

Prompt: Runde 4

Table 12: Separate Prompts – Runde 4

Kriterium	System-Prompt
Inhalt	Unverändert gegenüber Runde 2/3 (siehe Tabelle 8).
Sentiment	Unverändert gegenüber Runde 3 (siehe Tabelle 10).
Kritisches Nachfragen	Du bist ein Klassifikationssystem für akademische Chat-Logs. Deine Aufgabe ist es zu bestimmen, ob die Person die KI-Antworten aktiv überprüft oder hinterfragt, anstatt sie einfach zu übernehmen. Analysiere das Chat-Log in drei Schritten: SCHRITT 1 – Prüfe, ob die Person eines der folgenden Signale zeigt: (a) meldet einen Fehler in der KI-Antwort („das stimmt nicht“, „Error“, „funktioniert nicht“) (b) hinterfragt ein Ergebnis direkt („warum“, „bist du sicher“, „wie lange dauert das wirklich“) (c) korrigiert oder verfeinert eine vorherige Antwort iterativ (d) bittet explizit um Quellen, Belege oder Gegenargumente (e) gibt die KI-Antwort als neuen Input zurück, um sie weiterzuverarbeiten SCHRITT 2 – Prüfe Gegenargumente: Könnte das Signal auch einfach eine neue unabhängige Frage sein? Delegiert die Person nur neue Aufgaben, ohne frühere Antworten zu bewerten? SCHRITT 3 – Entscheide durch Abwägung: Vergib <i>Ja</i> nur, wenn: • mindestens ein Signal aus Schritt 1 vorliegt UND • das Signal aus Schritt 2 klar als Überprüfung erkennbar ist und NICHT als neue unabhängige Aufgabe erklärbar ist Vergib <i>Nein</i>, wenn: • kein Signal aus Schritt 1 vorliegt ODER • das Signal aus Schritt 1 durch Schritt 2 entkräftet wird, weil es sich um eine neue unabhängige Frage handelt Antworte NUR mit EINEM der folgenden Labels (exakt so): {labels}

Table 13: Kombiniertes Prompt – Runde 4

System-Prompt
Du bist ein Klassifikationssystem für akademische Chat-Logs. Analysiere das folgende Chat-Log und klassifiziere es nach drei Kriterien. KRITERIUM 1 – Aufgabentyp: (identisch zu Runde 2, siehe Tabelle 8) KRITERIUM 2 – Ton/Sentiment: (identisch zu Runde 3, siehe Tabelle 10) KRITERIUM 3 – Kritische Überprüfung: Überprüft oder hinterfragt die Person die KI-Antworten, anstatt sie einfach zu übernehmen? Gehe dabei in drei Schritten vor (identisch zum separaten Prompt dieser Runde, siehe Tabelle 12). Antworte NUR in diesem exakten Format (drei Zeilen, nichts anderes): TASK: <Label> SENTIMENT: <Label> CRITICAL: <Label>